

# Numerične metode 1 - definicije, trditve in izreki

Oskar Vavtar  
po predavanjih profesorja Bora Plestenjaka

2020/21

## Kazalo

<b>1</b>	<b>NUMERIČNO RAČUNANJE</b>	<b>3</b>
1.1	Uvod . . . . .	3
1.2	Premična pika . . . . .	3
1.3	Občutljivost problema . . . . .	4
1.4	Vrste napak pri numeričnem računanju . . . . .	4
1.5	Stabilnost metode . . . . .	5
1.6	Analiza zaokrožitvenih napak . . . . .	5
1.6.1	Produkt $n + 1$ predstavljivih števil . . . . .	5
1.6.2	Skalarni produkt vektorjev dolžine $n$ . . . . .	6
<b>2</b>	<b>NELINEARNE ENAČBE</b>	<b>7</b>
2.1	Uvod . . . . .	7
2.2	Bisekcija . . . . .	7
2.3	Navadna iteracija . . . . .	8
2.4	Tangentna metoda . . . . .	9
2.5	Metode brez $f'$ . . . . .	10
<b>3</b>	<b>SISTEMI LINEARNIH ENAČB</b>	<b>11</b>
3.1	Oznake in definicije . . . . .	11
3.2	Vektorske in matrične norme . . . . .	12
3.3	Občutljivost sistemov linearnih enačb . . . . .	14
3.4	LU razcep . . . . .	14
3.5	Stabilnost reševanja sistemov in LU razcepov . . . . .	16
<b>4</b>	<b>SISTEMI NELINEARNIH ENAČB</b>	<b>18</b>
4.1	Uvod . . . . .	18
4.2	Navadna iteracija . . . . .	18
4.3	Newtonova metoda . . . . .	19
<b>5</b>	<b>LINEARNI PROBLEM NAJMANJŠIH KVADRATOV</b>	<b>20</b>
5.1	Uvod . . . . .	20
5.2	Razcep Cholskega . . . . .	20
5.3	QR razcep . . . . .	22
5.4	Givensove rotacije . . . . .	22
5.5	Householderjeva zrcaljenja . . . . .	23
5.6	Singularni razcep (SVD) . . . . .	24

# 1 NUMERIČNO RAČUNANJE

## 1.1 Uvod

**Definicija 1.1** (Napaka). Pri numeričnem računanju izračunamo numerični približek za točno rešitev. Razlika med približkom in točno vrednostjo je *napaka* približka. Ločimo *absolutno* in *relativno* napako.

- absolutna napaka = približek – točna vrednost
- relativna napaka =  $\frac{\text{absolutna napaka}}{\text{točna vrednost}}$

Naj bo  $x$  točna vrednost,  $\hat{x}$  pa približek za  $x$ .

- Če je  $\hat{x} = x + d_a$ , potem je  $d_a = \hat{x} - x$  *absolutna napaka*.
- Če je  $\hat{x} = x(1 + d_r)$ , potem je  $d_r = \frac{\hat{x} - x}{x}$  *relativna napaka*.

## 1.2 Premična pika

**Definicija 1.2.** Velja  $\text{fl}(x) = x(1 + \delta)$  za  $|\delta| \leq u$ , kjer je

$$u = \frac{1}{2}b^{1-t}$$

*osnovna zaokrožitvena napaka:*

- single:  $u = 2^{-24} = 6 \times 10^{-8}$
- double:  $u = 2^{-53} = 1 \times 10^{-16}$

**Izrek 1.** Če za število  $x$  velja, da  $|x|$  leži na intervalu med najmanjšim in največjim *pozitivnim predstavljivim normaliziranim* številom, potem velja

$$\frac{|\text{fl}(x) - x|}{|x|} \leq u.$$

### 1.3 Občutljivost problema

**Definicija 1.3** (Občutljivost). Če se rezultat pri majhni spremembi argumentov<sup>1</sup> ne spremeni veliko, je problem *neobčutljiv*, sicer pa je *občutljiv*.

### 1.4 Vrste napak pri numeričnem računanju

**Definicija 1.4.** Pri numeričnem računanju se pojavijo 3 vrste napak:

1. NEODSTRANLJIVE NAPAKE: Npr. ko podatek ni predstavljivo število. Namesto  $y = f(x)$  lahko v najboljšem primeru izračunamo  $\bar{y} = f(\bar{x})$ , kjer je  $\bar{x}$  najbližje predstavljivo število.

$$D_n = y - \bar{y} = f(x) - f(\bar{x})$$

2. NAPAKA METODE: Npr. ko na voljo nimamo željene operacije. Namesto  $f(\bar{x})$  potem izračunamo  $\tilde{y} = g(\bar{x})$ , kjer je  $g(x)$  približek za  $f(x)$ , kjer znamo vrednost  $g$  izračunati s končnim številom operacij.

$$D_m = \bar{y} - \tilde{y} = f(\bar{x}) - g(\bar{x})$$

3. ZAKROŽITVENE NAPAKE: Pri izračunu  $\tilde{y} = g(\bar{x})$  lahko pri vsaki osnovni operaciji pride do zaokrožitvene napake, zato na koncu kot numeričen rezultat dobimo  $\hat{y}$ .

$$D_z = \tilde{y} - \hat{y}$$

Skupna napaka:

$$D = D_n + D_m + D_z$$

V splošnem lahko ocenimo:

$$|D| \leq |D_n| + |D_m| + |D_z|$$

---

<sup>1</sup> Motnji oz. perturbaciji.

## 1.5 Stabilnost metode

**Definicija 1.5.** Če metoda za  $\forall x$  vrne  $\hat{y}$ , ki je *absolutno (relativno)* blizu točnemu  $y$ , je metoda *direktno stabilna*.

Če metoda za  $\forall x$  vrne tak  $\hat{y}$ , da  $\exists \hat{x}$  absolutno (relativno) blizu  $x$ , da je  $\hat{y} = f(\hat{x})$  (točno), je metoda *obratno stabilna*.

V splošnem:

$$|\text{direktna napaka}| \leq |\text{občutljivost}| \cdot |\text{obratna napaka}|$$

## 1.6 Analiza zaokrožitvenih napak

### 1.6.1 Produkt $n + 1$ predstavljivih števil

**Algoritem.** Dana so predstavljiva števila  $x_0, x_1, \dots, x_n$ ; računamo  $p = x_0 \cdot x_1 \cdot \dots \cdot x_n$ .

TOČNO:

```
p0 = x0
i = 1, ..., n
    pi = pi-1 · xi
p = pn
```

NUMERIČNO:

```
 $\hat{p}_0 = x_0$ 
 $i = 1, \dots, n$ 
     $\hat{p}_i = \hat{p}_{i-1} \cdot x_i \cdot (1 + \delta_i) \quad |\delta_i| \leq u$ 
 $\hat{p} = \hat{p}_n$ 
```

### 1.6.2 Skalarni produkt vektorjev dolžine $n$

**Algoritem.** Imamo vektorje *predstavljivi* števil  $a = [a_1, \dots, a_n]^T$ ,  $b = [b_1, \dots, b_n]^T$ . Računamo  $s = \langle b^T, a \rangle = \sum_{i=1}^n a_i b_i$ .

TOČNO:

```
s0 = 0
i = 1, ..., n
    pi = ai · bi
    si = si-1 + pi
s = sn
```

NUMERIČNO:

```
ŝ0 = 0
i = 1, ..., n
    p̂i = ai · bi · (1 + αi)    |αi| ≤ u
    ŝi = (ŝi-1 + p̂i) · (1 + βi)  |βi| ≤ u
ŝ = ŝn
```

**Trditev 1.** Računanje skalarnega produkta je *obratno* stabilno, ni pa *direktno* stabilno.

## 2 NELINEARNE ENAČBE

### 2.1 Uvod

**Definicija 2.1.** Naj bo  $\alpha$  ničla funkcije  $f$ , ki je *zvezno odvedljiva* v okolici  $\alpha$ :

- $f'(\alpha) \neq 0$ :  $\alpha$  je *enostavna* ničla
- $f'(\alpha) = 0$ :  $\alpha$  je *večkratna* ničla

Če je  $f$   $m$ -krat zvezno odvedljiva in

$$f'(\alpha) = f''(\alpha) = \dots = f^{(m-1)}(\alpha) = 0, \quad f^{(m)}(\alpha) \neq 0,$$

je  $\alpha$   $m$ -kratna ničla.

**Trditev 2** (Občutljivost ničel). Naj bo  $\alpha$  enostavna ničla. Če v okolici  $x = \alpha$  obstaja inverzna funkcija  $\alpha = f^{-1}(0)$  v bistvu "računamo" vrednost inverzne funkcije. Občutljivost je enaka absolutni vrednosti odvoda inverzne funkcije:

$$|(f^{-1})'(0)| = \frac{1}{|f'(f^{-1}(0))|} = \frac{1}{|f'(\alpha)|}.$$

Večkratno ničlo lahko izračunamo le z natančnostjo  $u^{\frac{1}{m}}$ , kjer je  $m$  večkratnost ničle (za dvojno ničlo dobimo le polovico točnih decimal, za trojno le tretjino...).

### 2.2 Bisekcija

**Izrek 2.** Če je  $f$  realna zvezna funkcija na  $[a, b]$  in je  $f(a) \cdot f(b) < 0$ , potem  $\exists \xi \in (a, b)$ , da je  $f(\xi) = 0$ .

**Algoritem** (Bisekcija). Naj velja  $f(a) \cdot f(b) < 0$  in  $a < b$ :

```
e = b - a
while e > ε
    e = e/2, c = a + e
    if sign(f(c)) = sign(f(a))
        a = c
    else
        b = c
```

## 2.3 Navadna iteracija

**Algoritem** (Navadna iteracija).

```
izberi  $x_0$ 
r = 0, 1, 2, ...
 $x_{r+1} = g(x_r)$ 
```

Ustavitveni kriterij:

- a)  $r > r_{max}$  (prekoračeno število korakov)
- b)  $|r_{x+1} - r_x| < \varepsilon$

**Izrek 3.** Naj bo  $\alpha = g(\alpha)$  in naj iteracijska funkcija  $g$  na intervalu  $I = [\alpha - \delta, \alpha + \delta]$  za nek  $\delta > 0$  zadošča Lipschitzovem pogoju

$$|g(x) - g(y)| \leq m|x - y| \text{ za } x, y \in I, 0 \leq m < 1.$$

Potem za  $\forall x_0 \in I$  zaporedje  $x_{r+1} = g(x_r)$ ,  $r = 0, 1, \dots$  konvergira k  $\alpha$  in velja

- $|x_r - \alpha| \leq m^r \cdot |x_0 - \alpha|$
- $|x_{r+1} - \alpha| \leq \frac{m}{1-m} \cdot |x_{r+1} - x_r|$



**Posledica.** Naj bo  $\alpha = g(\alpha)$ ,  $g$  zvezno odvedljiva in  $|g'(\alpha)| < 1$ . Potem  $\exists \delta > 0$ , da za  $\forall x_0 \in [\alpha - \delta, \alpha + \delta]$  zaporedje  $x_{r+1} = g(x_r)$  konvergira k  $\alpha$ .

**Definicija 2.2.** Naj zaporedje  $\{x_r\}$  konvergira proti  $\alpha$ <sup>2</sup>. Pravimo, da zaporedje konvergira z redom konvergence  $p$ , če obstaja limita

$$\lim_{r \rightarrow \infty} \frac{|x_{r+1} - \alpha|}{|x_r - \alpha|^p} = C > 0.$$

**Izrek 4.** Naj bo iteracijska funkcija  $g$   $p$ -krat zvezno odvedljiva v okolici negibne točke  $\alpha$ . Če velja  $g'(\alpha) = \dots = g^{(p-1)}(\alpha) = 0$  in  $g^{(p)}(\alpha) \neq 0$ , potem zaporedje  $x_{r+1} = g(x_r)$ ,  $r = 0, 1, \dots$ , v okolici  $\alpha$  konvergira z redom  $p$ . V primeru  $p = 1$  mora za konvergenco veljati še  $|g'(\alpha)| < 1$ .

## 2.4 Tangentna metoda

**Metoda.**

$$x_{r+1} = x_r - \frac{f(x_r)}{f'(x_r)}$$

Konvergenca:

$$|e_{r+1}| \approx C \cdot |e_r|^2$$

**Posledica.** Če je  $f$  dvakrat zvezno odvedljiva v okolici ničle  $\alpha$ , potem tangentna metoda za dovolj dober začetni približek  $x_0$  vedno konvergira k  $\alpha$ .

**Izrek 5.** Naj bo funkcija  $f$  na  $I = [a, \infty)$  dvakrat zvezno odvedljiva, naraščajoča in ima ničlo na  $\alpha \in I$ . Potem je  $\alpha$  edina ničla na  $I$  in za  $\forall x_0 \in I$  tangentna metoda konvergira le k  $\alpha$ .

---

<sup>2</sup>  $\lim_{r \rightarrow \infty} x_r = \alpha$

## 2.5 Metode brez $f'$

**Metoda** (Sekantna metoda).

$$x_{r+1} = x_r - \frac{f(x_r)(x_r - x_{r-1})}{f(x_r) - f(x_{r-1})}$$

Konvergenca:

$$|e_{r+1}| \approx C \cdot |e_r| \cdot |e_{r-1}|$$

**Metoda** (Mullerjeva metoda). Skozi točke  $(x_r, f(x_r))$ ,  $(x_{r-1}, f(x_{r-1}))$ ,  $(x_{r-2}, f(x_{r-2}))$  potegnemo kvadratni polinom  $y = p(x)$  in za  $x_{r+1}$  vzamemo tisto ničlo polinoma  $p$ , ki je bližje  $x_r$ .

Konvergenca:

$$|e_{r+1}| \approx C \cdot |e_r| \cdot |e_{r-1}| \cdot |e_{r-2}|$$

**Metoda** (Inverzna interpolacija). Zamenjamo vlogi  $x$  in  $y$  in vzamemo kvadratni polinom  $x = \mathcal{L}(y)$ , ki gre skozi točke  $(f(x_r), x_r)$ ,  $(f(x_{r-1}), x_{r-1})$ ,  $(f(x_{r-2}), x_{r-2})$ . Za  $x_{r+1}$  vzamemo

$$x_{r+1} = \mathcal{L}(0).$$

Red konvergence je enak kot pri *Mullerjevi metodi*.

### 3 SISTEMI LINEARNIH ENAČB

#### 3.1 Oznake in definicije

**Definicija 3.1.** Sistem  $n$  linearnih enačb z  $n$  neznankami pišemo v obliki

$$Ax = b, \quad A \in \mathbb{R}^{n \times n} \ (\mathbb{C}^{n \times n}), \quad x, b \in \mathbb{R}^n \ (\mathbb{C}^n).$$

**Definicija 3.2.** Skalarni produkt vektorjev  $x$  in  $y$  je enaka

a)  $x, y \in \mathbb{R}^n$ :

$$y^T x = \sum_{i=1}^n x_i y_i = \langle x, y \rangle = \langle y, x \rangle$$

b)  $x, y \in \mathbb{C}^n$ :

$$y^H x = \sum_{i=1}^n x_i \overline{y_i} = \langle x, y \rangle = \overline{\langle y, x \rangle}$$

**Definicija 3.3.** Množenje vektorja  $x$  z matriko  $A$ :

a)

$$y_i = \sum_{k=1}^n a_{ik} x_k = \alpha_i^T x$$

b)

$$y = \sum_{i=1}^n x_i a_i$$

**Definicija 3.4.**  $A \in \mathbb{R}^{n \times n}$  je *nesingularna*, če (ekvivalentno):

- a)  $\det(A) \neq 0$
- b) obstaja inverz  $A^{-1}$ , da je  $A^{-1}A = AA^{-1} = I$
- c)  $\text{rang}(A) = n$
- d) za  $\forall x \neq 0$  je  $Ax \neq 0$
- e)  $\ker(A) = \{x \mid Ax = 0\} = \{0\}$

**Definicija 3.5.** Matrika je *simetrično pozitivno definitna*, če  $A = A^T$  in  $x^T Ax > 0$  za  $x \neq 0$ .

**Definicija 3.6.** Če za  $x \neq 0$  velja  $Ax = \lambda x$ , je  $\lambda$  lastna vrednost in  $x$  lastni vektor. Vsaka matrika ima  $n$  lastnih vrednosti, ki so ničle karakterističnega polinoma

$$p(\lambda) := \det(A - \lambda I).$$

### 3.2 Vektorske in matrične norme

**Definicija 3.7.** Vektorska norma je preslikava  $\|\cdot\| : \mathbb{C}^n \rightarrow \mathbb{R}$ , da velja:

- 1) Nenegativnost:

$$\|x\| \geq 0, \quad \|x\| = 0 \Leftrightarrow x = 0$$

- 2) Homogenost:

$$\|\alpha x\| = |\alpha| \cdot \|x\|$$

- 3) Trikotniška neenakost:

$$\|x + y\| \leq \|x\| + \|y\|$$

**Definicija 3.8.** Matrična norma je preslikava  $\|\cdot\| : \mathbb{C}^{n \times n} \rightarrow \mathbb{R}$ , da velja:

1) Nenegativnost:

$$\|A\| \geq 0, \quad \|A\| = 0 \Leftrightarrow A = 0$$

2) Homogenost:

$$\|\alpha A\| = |\alpha| \cdot \|A\|$$

3) Trikotniška neenakost

$$\|A + B\| \leq \|A\| + \|B\|$$

4) Submultiplikativnost:

$$\|A \cdot B\| \leq \|A\| \cdot \|B\|$$

za  $\forall A, B \in \mathbb{C}^{n \times n}$  in  $\forall \alpha \in \mathbb{C}$ .

**Lema 1** (Operatorska norma). Če je za poljubno vektorsko normo  $\|\cdot\|_v$  definiramo

$$\|A\| := \max_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v},$$

je to matrična norma.

**Lema 2.**

$$\|A\|_1 = \max_{j=1,\dots,n} \|a_j\|_1 = \max_{j=1,\dots,n} \sum_{i=1}^n |a_{ij}|$$

**Lema 3** (Spektralna norma).

$$\|A\|_2 = \sigma_1(A) = \max_{i=1,\dots,n} \sqrt{\lambda_i(A^H A)}$$

**Lema 4.** Za vsako matrično normo  $\|\cdot\|_m$  obstaja taka vektorska norma  $\|\cdot\|_v$ , ki je z njo usklajena, kar pomeni, da za vse pare  $A, x$  velja

$$\|Ax\|_v \leq \|A\|_m \cdot \|x\|_v.$$

**Lema 5.** Za vsako lastno vrednost  $\lambda$  in poljubno matrično normo  $\|A\|$  velja:

$$|\lambda| \leq \|A\|.$$

### 3.3 Občutljivost sistemov linearnih enačb

**Lema 6.** Če je  $\|X\| < 1$ , potem velja:

a)  $I - X$  je *nesingularna*

b)  $(I - X)^{-1} = \sum_{i=0}^{\infty} X^i = I + X + X^2 + \dots$

c) Če je  $\|I\| = 1$ , je  $\|(I - X)^{-1}\| \leq \frac{1}{1 - \|X\|}$

**Izrek 6.** Naj bo  $A$  *nesingularna* in  $\Delta A$  taka motnja, da je  $\|\Delta A\| < \frac{1}{\|A^{-1}\|}$ . Če je  $Ax = b$  in  $(A + \Delta A)(x + \Delta x) = b + \Delta b$ , potem velja:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{K(A)}{1 - K(A) \frac{\|\Delta A\|}{\|A\|}} \left( \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right),$$

kjer je  $K(A) = \|A\| \cdot \|A^{-1}\|$ .

### 3.4 LU razcep

**Izrek 7.** Za matriko  $A$  je ekvivalentno:

- 1) Obstaja enoličen razcep  $A = LU$
- 2) Vse vodilne podmatrike  $A_k = A(1 : k, 1 : k)$  so nesingularne

**Algoritem** (LU razcep).

$$\begin{aligned}
 j &= 1, \dots, n-1 \\
 i &= j+1, \dots, n \\
 l_{ij} &= \frac{a_{ij}}{a_{jj}} \\
 k &= j+1, \dots, n \\
 a_{ik} &= a_{ik} - l_{ij}a_{jk}
 \end{aligned}$$

Zahtevnost algoritma je odvisna od števila operacij. Preštejmo osnovne računske operacije:

$$\sum_{j=1}^{n-1} \left( \sum_{i=j+1}^n \left( 1 + \sum_{k=j+1}^n 2 \right) \right) = \frac{(n-1)n}{2} + 2 \frac{(n-1)n(2n-1)}{6} = \frac{2}{3}n^3 + \sigma(n^2)$$

**Algoritem** (Prema substitucija).

Sistem  $Ly = b$  rešujemo s premo substitucijo:

$$\begin{aligned}
 i &= 1, \dots, n \\
 y_i &= b_i - \sum_{j=1}^{i-1} l_{ij}y_j
 \end{aligned}$$

Število operacij:

$$\sum_{i=1}^n (1 + 2(i-1)) = n + 2 \frac{(n-1)n}{2} = n^2$$

**Algoritem.**

$$\begin{aligned}
 i &= n, n-1, \dots, 1 \\
 x_i &= \frac{1}{u_{ii}} (y_i - \sum_{j=i+1}^n u_{ij}x_j)
 \end{aligned}$$

Število opracij:

$$n^2 + n$$

**Algoritem** (LU razcep z delnim pivotiranjem).

```

j = 1, ..., n-1
  poisci |apj| = maxj ≤ l ≤ n |alj|
  zamenjaj vrstici j in p
  i = j+1, ..., n
    lij =  $\frac{a_{ij}}{a_{jj}}$ 
    k = j+1, ..., n
      aik = aik - lijajk

```

Pri pivotiranju vedno velja  $|l_{ij}| \leq 1$ , saj saj je  $|a_{ij}| \leq |a_{jj}|$

**Izrek 8.** Če je  $\det(A) \neq 0$ , potem obstaja taka permutacijska matrika  $P$ , da obstaja LU razcep

$$PA = LU,$$

kjer je  $L$  spodnjetrokotniška matrika,  $U$  pa zgornjetrikotniška matrika.

### 3.5 Stabilnost reševanja sistemov in LU razcepov

**Lema 7.** Naj bo  $L$  nesingularna spodnje trikotna matrika velikosti  $n \times n$ . Če sistem  $Ly = b$  rešimo s premo substitucijo, potem izračunani  $\hat{y}$  zadošča

$$(L + \Delta L)\hat{y} = b,$$

kjer je  $|\Delta L| \leq nu|L|$ . Reševanje spodenje trikotnega sistema s premo substitucijo je torej obratno stabilno.

**Lema 8.** Naj bo  $U$  zgornje trikotna matrika velikosti  $n \times n$ ,  $\det U \neq 0$ . Če sistem  $Ux = y$  rešimo z obratno substitucijo, potem numerično izračunani  $\hat{x}$  zadošča

$$(U + \Delta U)\hat{x} = y,$$

kjer je

$$|\Delta U| \leq nu|U|.$$

Reševanje z obratno substitucijo je tudi obratno stabilno.



**Lema 9.** Naj bo  $A$  *nesingularna* matrika velikosti  $n \times n$ , kjer se izvede LU razcep brez pivotiranja. Za izračunani matriki  $\hat{L}$  in  $\hat{U}$  velja

$$A + E = \hat{L}\hat{U},$$

kjer je

$$|E| \leq nu|\hat{L}||\hat{U}|.$$

**Izrek 9.** Za izračunano rešitev  $\hat{x}$  sistema linearnih enačb  $Ax = b$  z uporabo LU razcepa velja

$$(A + \Delta A)\hat{x} = b,$$

kjer je

$$|\Delta A| \leq 3nu|L||U| + \sigma(u^2).$$

## 4 SISTEMI NELINEARNIH ENAČB

### 4.1 Uvod

**Definicija 4.1.** Sistem nelinearnih enačb je sistem oblike

$$\begin{aligned} f_1(x_1, \dots, x_n) &= 0 \\ &\vdots \\ f_n(x_1, \dots, x_n) &= 0 \end{aligned}$$

za  $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ . Krajše zapišemo kot

$$F(x) = 0, \quad F = \begin{bmatrix} f_1 \\ \vdots \\ f_n \end{bmatrix},$$

kjer je  $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$  in  $x \in \mathbb{R}^n$ .

### 4.2 Navadna iteracija

**Metoda.** To je posplošitev navadne iteracije za eno spremenljivko. Poiščemo funkcijo  $G : \mathbb{R}^n \rightarrow \mathbb{R}^n$ , da velja

$$F(\alpha) = 0 \Leftrightarrow \alpha = G(\alpha), \quad \alpha \in \mathbb{R}^n.$$

Izberemo  $x^{(0)} \in \mathbb{R}^n$  in tvorimo zaporedje

$$x^{(r+1)} = G(x^{(r)}), \quad r = 0, 1, \dots$$

**Izrek 10.** Naj bo  $G : \mathbb{R}^n \rightarrow \mathbb{R}^n$  zvezno odvedljiva na  $\Omega \subset \mathbb{R}^n$ . Če velja:

- a)  $x \in \Omega \Rightarrow G(x) \in \Omega$
- b)  $x \in \Omega \Rightarrow \rho(JG(x)) \leq m < 1$

potem ima  $G$  v  $\Omega$  natanko eno negibno točko  $\alpha$  in zaporedje  $x^{(r+1)} = G(x^{(r)})$ ,  
 $r = 0, 1, \dots$ , za  $\forall x^{(0)} \in \Omega$  konvergira k  $\alpha$ . Tu je  $JG(x) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1}(x) & \dots & \frac{\partial g_1}{\partial x_n}(x) \\ \vdots & \ddots & \vdots \\ \frac{\partial g_n}{\partial x_1}(x) & \dots & \frac{\partial g_n}{\partial x_n}(x) \end{bmatrix}$   
 Jacobijeva matrika parcialnih odvodov in  $\rho$  spektralni radij<sup>3</sup>.

### 4.3 Newtonova metoda

**Metoda.** Naj bo  $x$  približek za ničlo funkcije  $f$ . Iščemo popravek  $\Delta x$ , da bo  $F(x + \Delta x) = 0$ . Z uporabo razvoja v Taylorjevo vrsto dobimo

$$F(x + \Delta x) = F(x) + JF(x) \cdot \Delta x + \underbrace{\mathcal{O}(\|\Delta x\|^2)}_{\text{zanemarimo}}.$$

Iz tega sledi  $\Delta x = -JF(x)^{-1} \cdot F(x)$ , za nov približek vzamemo torej

$$x + \Delta x = x - JF(x)^{-1} \cdot F(x),$$

za iteracijsko funkcijo pa

$$G(x) = x - JF(x)^{-1} \cdot F(x).$$

**Algoritem.**

```

 $\mathbf{x}^{(0)}$ 
 $\mathbf{r} = 0, 1, \dots$ 
   $JF(\mathbf{x}^{(\mathbf{r})}) \cdot \Delta \mathbf{x}^{(\mathbf{r})} = -F(\mathbf{x}^{(\mathbf{r})})$ 
   $\mathbf{x}^{(\mathbf{r}+1)} = \mathbf{x}^{(\mathbf{r})} + \Delta \mathbf{x}^{(\mathbf{r})}$ 

```

---

<sup>3</sup>Največja absolutna vrednost lastnih vrednosti.

## 5 LINEARNI PROBLEM NAJMANJŠIH KVADRATOV

### 5.1 Uvod

**Metoda.** To je primer predločenega sistema, kjer imamo več enačb kot neznank. V splošnem<sup>4</sup> nima rešitve. Namesto tega iščemo  $x$ , ki minimizira normo ostanka  $Ax - b$ . Če iščemo minimum  $\|Ax - b\|_2$ , potem je to linearni problem najmanjših kvadratov. Ustrezen  $x$  je rešitev po *metodi najmanjših kvadratov*.

**Izrek 11.** Naj bo  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ ,  $m \geq n$ ,  $\text{rang}(A) = n$ . Rešitev normalnega sistema

$$A^T Ax = A^T b$$

je rešitev predločenega sistema  $Ax = b$  po metodi najmanjših kvadratov.

**Opomba.** Pravilna izpeljava:

$$A^T(Ax - b) = 0 \Rightarrow A^T Ax = A^T b$$

### 5.2 Razcep Cholskega

**Izrek 12.** Dan je sistem  $Bx = c$ ,  $B$  je simetrična pozitivno definitna<sup>5</sup> matrika velikosti  $n \times n$ . Velja:

1. Če je  $B$  simetrična pozitivno definitna  $\Rightarrow$  vse njene vodilne podmatrike so simetrične pozitivno definitne.
2. Če je  $B$  simetrična pozitivno definitna  $\Rightarrow$  obstaja LU razcep  $B = LU$ , kjer je  $u_{ii} > 0$  za  $i = 1, \dots, n$ .

---

<sup>4</sup>Razen v primeru kot je  $b \in \text{Im}(A)$

<sup>5</sup> $B = B^T$ ,  $z^T B z > 0$  za  $z \neq 0$

3.  $B$  je simetrično pozitivno definitna  $\Leftrightarrow$  obstaja nesingularna spodnje trikotna matrika  $U$ , da je  $B = UU^T$ ,  $u_{ii} > 0$  za  $i = 1, \dots, n$ .

**Algoritem.**

$k = 1, \dots, n$

$$v_{kk} = (b_{kk} - \sum_{i=1}^{k-1} v_{ki}^2)^{\frac{1}{2}}$$

$j = k + 1, \dots, n$

$$v_{jk} = \frac{1}{v_{kk}} (b_{jk} - \sum_{i=1}^{k-1} v_{ji} v_{ki})$$

Število operacij:

$$\sum_{k=1}^n (2k + 2(n-k)k) = \frac{1}{3}n^3 + \mathcal{O}(n^2)$$

**Metoda.** Reševanje sistema  $Bx = c$ ,  $B$  je simetrična pozitivno definitna matrika:

1.  $B = VV^T$
2. reši  $Vy = b$
3. reši  $V^T x = y$

**Metoda.** Dana je  $A \in \mathbb{R}^{m \times n}$ ,  $m > n$ ,  $\text{rang}(A) = n$ . Po metodi najmanjših kvadratov iščemo  $x$ .  $A^T A$  je simetrična, uporabimo razcep Choleskega:

1.  $B = A^T A$ ,  $c = A^T b$
2.  $B = VV^T$ ,  $V$  je spodnje trikotna matrika
3. reši  $Vy = c$
4. reši  $V^T x = y$

### 5.3 QR razcep

**Izrek 13.** Naj bo  $A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ ,  $\text{rang}(A) = n$ . Potem obstaja enoličen razcep  $A = QR$ , kjer je  $Q$  matrika velikosti  $m \times n$  z ortonormiranimi stolpci in  $R$  zgornje trikotna matrika velikosti  $n \times n$  s pozitivnimi diagonalnimi elementi.

**Algoritem.**

```

k = 1, ..., n
  q_k = a_k
  i = 1, ..., k-1
    r_ik = q_i^T · a_k
    q_k = q_k - r_ik · q_i
  r_kk = ||q_k||_2
  q_k = 1/r_kk q_k

```

Število operacij:

$$\sum_{k=1}^n \left( \sum_{i=1}^{k-1} (2m + 2m) + 2m + 1 + m \right) = 2mn^2 + \mathcal{O}(mn)$$

### 5.4 Givensove rotacije

**Algoritem.**

```

Q̃ = I_m (Ce potrebuje Q̃)
i = 1, ..., n
  k = i+1, ..., m
    r = (a_ii^2 + a_ki^2)^{1/2}, c = a_ii/r, s = a_ki/r
    A([i k], i:n) = [ c s ] A([i k], i:n)
                    [-s c]
    b([i k]) = [ c s ] b([i k]) (Ce resujemo Ax = b po m.n.k.)
                [-s c]
    Q̃([i k], :) = [ c s ] Q̃([i k], :)
                  [-s c]
Q̃ = Q̃^T

```

Število operacij:

$$\sum_{i=1}^n \sum_{k=i+1}^m (6 + 6(n-i+1) + 6) \approx \sum_{i=1}^n 6(n-i)(m-i) = 3mn^2 - n^3$$

Če potrebujemo  $\tilde{Q}$ , je to še dodatnih  $6m^2n - 3mn^2$  operacij.

## 5.5 Householderjeva zrcaljenja

**Algoritem.**

```

 $\tilde{Q} = I_m$  (Ce potrebujemo  $\tilde{Q}$ )
 $i = 1, \dots, n$  (v primeru  $m=n$  le do  $n-1$ )
    dolocí  $w_i \in \mathbb{R}^{m-n+1}$ , ki prezrcali  $A(i:m, i)$  v  $\pm * \cdot e_1$ 
     $A(i:m, i:n) = P_i \cdot A(i:m, i:n)$ 
     $b(i:m) = P_i \cdot b(i:m)$ 
     $\tilde{Q}(i:m, :) = P_i \cdot \tilde{Q}(i:m, :)$ 
 $\tilde{Q} = \tilde{Q}^T$ 

```

Število operacij:

$$\begin{aligned} \sum_{i=1}^n (2(m-i+1) + (n-i+1)4(m-i+1) + 4(m-i+1)) &\approx \\ &\approx \sum_{i=1}^n 4(n-i)(m-i) \approx 2mn^2 - \frac{2}{3}n^3 \end{aligned}$$

Če potrebujemo še  $\tilde{Q}$  porabimo še dodatnih  $4m^2n - 2mn^2$  operacij.

## 5.6 Singularni razcep (SVD)

**Izrek 14.** Za  $A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ , obstaja razcep  $A = U\Sigma V^T$ , kjer je  $U$  ortogonalna matrika velikosti  $m \times m$ ,  $V$  ortogonalna matrika velikosti  $n \times n$  in  $\Sigma$  matrika velikosti  $m \times n$  oblike

$$\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_n & \\ & & & \end{bmatrix},$$

kjer so  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$  singularne vrednosti matrike  $A$ .

**Lema 10.** Naj bo  $A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ ,  $\text{rang}(A) = n$ . Potem je za  $b \in \mathbb{R}^m$  minimum  $\|Ax - b\|_2$  dosežen pri

$$x = \sum_{i=1}^n \frac{u_i^T b}{\sigma_i} v_i.$$

**Trditev 3.** Naj bo  $A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ ,  $\text{rang}(A) = r < n$ . Če je  $A = U\Sigma U^T$  singularni razcep  $A$ , potem ima izmed vseh vektorjev  $x \in \mathbb{R}^n$ , ki minimizirajo  $\|Ax - b\|_2$ , najmanjšo normo  $\|x\|_2$  vektor

$$x = \sum_{i=1}^r \frac{u_i^T b}{\sigma_i} v_i.$$

**Definicija 5.1.** Matrike  $X \in \mathbb{R}^{n \times m}$  je pseudoinverz matrike  $A$ , če zadošča naslednjim pogojem:

1.  $AXA = A$
2.  $XAX = X$
3.  $(AX)^T = AX$
4.  $(XA)^T = XA$



Če je  $A$  matrika velikosti  $n \times n$ ,  $\det(A) \neq 0$ , potem je

$$A^+ = A^{-1}.$$

Če je  $A$  matrika velikosti  $m \times n$ ,  $\text{rang}(A) = r$ ,  $m \geq n$ , potem je

$$A^+ = (A^T A)^{-1} A^T.$$

**Izrek 15.** Za  $A \in \mathbb{R}^{m \times n}$ ,  $A = U \Sigma V^T$ , je

$$A^+ = V \Sigma^+ U^T,$$

kjer je

$$\Sigma^+ = \begin{bmatrix} \sigma_1^{-1} & & & & & \\ & \ddots & & & & \\ & & \sigma_r^{-1} & & & \\ & & & 0 & & \\ & & & & \ddots & \\ & & & & & 0 \end{bmatrix},$$

če je  $\text{rang}(A) = r$ .

Če je  $A = U \Sigma V^T$ , je

$$\begin{aligned} A &= \sum_{i=1}^r \sigma_i u_i v_i^T \\ A^+ &= \sum_{i=1}^r \frac{1}{\sigma_i} v_i u_i^T \\ A^+ b &= \sum_{i=1}^r \frac{u_i^T b}{\sigma_i} v_i \end{aligned}$$